

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THÀNH PHỐ HỒ CHÍ MINH



BÁO CÁO ĐỀ TÀI HỆ KHUYẾN NGHỊ

**ĐỀ TÀI: HỆ THỐNG GỢI Ý MÓN ĂN (FOOD RECOMMENDATION
SYSTEM)**

Nhóm thực hiện: Nhóm 15

Nguyễn Ngọc Lâm - 22635801

Nguyễn Tấn Minh - 22643511

Nguyễn Hữu Phúc - 22676511

Lớp: DHKHD18A - 420300411601

Người hướng dẫn: Lê Phúc Lữ

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2025

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP THÀNH PHỐ HỒ CHÍ MINH



BÁO CÁO ĐỀ TÀI HỆ KHUYẾN NGHỊ

**ĐỀ TÀI: HỆ THỐNG GỢI Ý MÓN ĂN (FOOD RECOMMENDATION
SYSTEM)**

Nhóm thực hiện: Nhóm 15

Nguyễn Ngọc Lâm - 22635801

Nguyễn Tấn Minh - 22643511

Nguyễn Hữu Phúc - 22676511

Lớp: DHKHD18A - 420300411601

Người hướng dẫn: Lê Phúc Lữ

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2025

MỤC LỤC

HỆ THỐNG GỢI Ý MÓN ĂN (FOOD RECOMMENDATION SYSTEM)	1
1. Giới thiệu.....	1
2. Dữ liệu và tiền xử lý.....	1
3. Cơ sở lý thuyết	2
3.1. Content-Based Filtering	2
3.1.1 Nguyên lý	2
3.1.2 Biểu diễn đặc trưng (Feature Representation)	2
3.1.3 Độ tương đồng giữa các món ăn	3
3.2. Collaborative Filtering	3
3.2.1 Nguyên lý	4
3.2.2 User-Based Collaborative Filtering	4
3.2.3 Item-Based Collaborative Filtering.....	5
3.3. Matrix Factorization.....	5
3.4 Hybrid Model	6
3.4.1 Nguyên lý	6
3.4.2 Các dạng kết hợp phổ biến.....	6
4. Mô hình và kết quả.....	7
5. Kết luận và hướng phát triển.....	8

HỆ THỐNG GỢI Ý MÓN ĂN (FOOD RECOMMENDATION SYSTEM)

1. Giới thiệu

Trong kỷ nguyên công nghệ số, việc cá nhân hóa trải nghiệm người dùng trở thành yếu tố cốt lõi giúp các nền tảng trực tuyến thu hút và giữ chân khách hàng. Một trong những ứng dụng phổ biến nhất của công nghệ cá nhân hóa là hệ thống gợi ý (Recommendation System). Trong lĩnh vực ẩm thực, hệ thống gợi ý món ăn đóng vai trò quan trọng trong việc hỗ trợ người dùng lựa chọn món phù hợp với sở thích, khẩu vị và nhu cầu dinh dưỡng cá nhân.

Đề tài này tập trung vào việc nghiên cứu và phân tích các phương pháp xây dựng hệ thống gợi ý món ăn, bao gồm: Content-Based Filtering, Collaborative Filtering, Matrix Factorization và mô hình lai (Hybrid Model). Mục tiêu là hiểu rõ nguyên lý hoạt động, ưu – nhược điểm của từng phương pháp, từ đó đề xuất hướng xây dựng một hệ thống gợi ý hiệu quả cho dữ liệu thực tế.

2. Dữ liệu và tiền xử lý

Dữ liệu đầu vào của hệ thống gợi ý món ăn thường bao gồm:

- Thông tin người dùng: `user_id`, tuổi, giới tính, vùng miền, lịch sử mua hàng.
- Thông tin món ăn: `food_id`, tên món, thành phần, loại món, giá, mức độ phổ biến.
- Dữ liệu tương tác: `rating`, lượt xem, lượt thêm vào giỏ hàng.

Quy trình tiền xử lý gồm các bước:

- Làm sạch dữ liệu: loại bỏ dữ liệu trùng, giá trị thiếu.
- Chuẩn hóa định dạng văn bản.
- Mã hóa dữ liệu danh mục (LabelEncoder, OneHotEncoder).
- Tính toán các vector đặc trưng cho mô hình Content-Based.
- Xây dựng ma trận người dùng – món ăn cho các mô hình Collaborative và Matrix Factorization.

3. Cơ sở lý thuyết

3.1. Content-Based Filtering

Phương pháp lọc dựa trên nội dung (Content-Based Filtering) hoạt động dựa trên nguyên tắc: “nếu người dùng thích một sản phẩm nào đó, họ cũng sẽ thích các sản phẩm có nội dung tương tự”. Trong hệ thống gợi ý món ăn, nội dung của một món có thể được mô tả thông qua các đặc trưng như: thành phần (ingredients), loại món (category), phong cách ẩm thực (cuisine), hoặc hương vị (taste profile).

Các bước chính của Content-Based Filtering:

- Tiền xử lý văn bản mô tả món ăn (chuẩn hóa, tách từ, loại bỏ stopwords).
- Biểu diễn văn bản bằng vector đặc trưng (TF-IDF, SBERT embeddings).
- Tính độ tương đồng giữa các món ăn bằng Cosine Similarity hoặc Euclidean Distance.
- Đưa ra danh sách các món có độ tương đồng cao nhất với món mà người dùng từng thích.

3.1.1 Nguyên lý

Ý tưởng: Gợi ý sản phẩm tương tự về đặc trưng nội dung so với sản phẩm người dùng đã thích.

Giả sử: Người dùng u đã thích món ăn i , hệ thống sẽ tìm các món j có vector đặc trưng gần với i nhất.

3.1.2 Biểu diễn đặc trưng (Feature Representation)

Mô tả món ăn được biểu diễn bằng vector đặc trưng:

TF-IDF:

$$TF-IDF(t, d) = TF(t, d) \times \log \frac{N}{DF(t)}$$

Trong đó:

- $TF(t, d)$: số lần xuất hiện của từ t trong món d
- $DF(t)$: số món chứa từ t
- N : tổng số món trong tập dữ liệu

SBERT Embedding: Đây là các kỹ thuật biểu diễn văn bản tiên tiến, sử dụng mô hình dựa trên kiến trúc **Transformer (như BERT)** để tạo ra vector ngữ nghĩa (Semantic Vectors) cho toàn bộ mô tả món ăn. Đặc biệt, SBERT Embedding cho phép tạo ra các embeddings chất lượng cao, đảm bảo rằng các món ăn có nội dung hoặc ngữ cảnh tương tự (ví dụ: mô tả có chứa "gà" và "thịt gà") sẽ có các vector nằm gần nhau trong không gian đặc trưng. Điều này giúp mô hình hiểu được sự đồng nghĩa và mối quan hệ ngữ cảnh giữa các thành phần nguyên liệu

3.1.3 Độ tương đồng giữa các món ăn

Thường dùng **Cosine Similarity**:

$$\text{sim}(i, j) = \frac{\vec{v}_i \cdot \vec{v}_j}{\|\vec{v}_i\| \|\vec{v}_j\|}$$

Hoặc **Euclidean Distance**:

$$d(i, j) = \sqrt{\sum_{k=1}^n (v_{ik} - v_{jk})^2}$$

Gợi ý: Chọn top-k món có độ tương đồng cao nhất với món mà người dùng đã thích:

$$\text{TopK}(i) = \underset{j \neq i}{\text{argmax}} \text{sim}(i, j)$$

3.2. Collaborative Filtering

Phương pháp lọc cộng tác (Collaborative Filtering – CF) dựa trên giả định rằng: “những người dùng có hành vi tương tự trong quá khứ sẽ có xu hướng thích các sản

phẩm giống nhau trong tương lai”. CF không cần thông tin nội dung của món ăn, mà chỉ cần dữ liệu tương tác người dùng – sản phẩm (như đánh giá, lượt xem, lượt mua).

Có hai hướng tiếp cận chính:

- User-Based CF: Gợi ý dựa trên sự tương đồng giữa người dùng.
- Item-Based CF: Gợi ý dựa trên sự tương đồng giữa các món ăn.

Độ tương đồng được tính toán bằng các thước đo như Cosine Similarity hoặc Pearson Correlation. CF là phương pháp phổ biến nhờ tính đơn giản và khả năng mở rộng, tuy nhiên dễ gặp vấn đề cold-start khi có người dùng hoặc món ăn mới.

3.2.1 Nguyên lý

Giả định: “Người dùng có hành vi giống nhau trong quá khứ sẽ có xu hướng thích các sản phẩm giống nhau trong tương lai”.

Sử dụng ma trận tương tác:

$$R_{m \times n} = [r_{ui}]$$

Với:

- r_{ui} : đánh giá (rating) mà người dùng u cho món i
- m : số người dùng, n : số món ăn

3.2.2 User-Based Collaborative Filtering

Tính độ tương đồng giữa hai người dùng u và v :

$$\text{sim}(u, v) = \frac{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{i \in I_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

(Công thức Pearson Correlation)

Dự đoán đánh giá món i của người dùng u :

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_u} \text{sim}(u, v) \cdot (r_{vi} - \bar{r}_v)}{\sum_{v \in N_u} |\text{sim}(u, v)|}$$

3.2.3 Item-Based Collaborative Filtering

Tính độ tương đồng giữa hai món i, j :

$$\text{sim}(i, j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)(r_{uj} - \bar{r}_u)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \bar{r}_u)^2}}$$

Dự đoán đánh giá:

$$\hat{r}_{ui} = \frac{\sum_{j \in N_i} \text{sim}(i, j) \cdot r_{uj}}{\sum_{j \in N_i} |\text{sim}(i, j)|}$$

Nhược điểm

- Cold-start: khó gợi ý khi có người dùng hoặc món ăn mới.
- Sparse data: dữ liệu đánh giá thưa thớt gây khó cho việc tính tương đồng.

3.3. Matrix Factorization

Matrix Factorization (MF) là một phương pháp nâng cao trong hệ khuyến nghị, giúp giảm chiều dữ liệu và phát hiện các đặc trưng tiềm ẩn (latent features) của người dùng và sản phẩm. Ý tưởng chính là phân rã ma trận tương tác người dùng – sản phẩm R thành hai ma trận nhỏ hơn: P (đặc trưng người dùng) và Q (đặc trưng sản phẩm), sao cho:

$$R \approx P \times Q^T$$

Các kỹ thuật thường dùng: Singular Value Decomposition (SVD), Alternating Least Squares (ALS). MF cho phép dự đoán các giá trị rating chưa biết, phù hợp với dữ liệu lớn và thưa (sparse).

Nguyên lý:

Phân rã ma trận người dùng – sản phẩm R thành hai ma trận ẩn:

$$R_{m \times n} \approx P_{m \times k} \times Q_{n \times k}^T$$

Trong đó:

- P_u : vector đặc trưng của người dùng u
- Q_i : vector đặc trưng của món ăn i
- k : số đặc trưng tiềm ẩn (latent features)

Hàm mất mát (Loss Function)

$$\min_{P,Q} \sum_{(u,i) \in K} (r_{ui} - P_u Q_i^T)^2 + \lambda (\|P_u\|^2 + \|Q_i\|^2)$$

Trong đó:

- λ : hệ số regularization để tránh overfitting
- K : tập các cặp (user, item) có đánh giá thật
- Giải bằng **Gradient Descent** hoặc **Alternating Least Squares (ALS)**

Dự đoán:

$$\hat{r}_{ui} = P_u Q_i^T$$

Ưu điểm:

- Hiệu quả cao với dữ liệu lớn, thưa.
- Có thể mở rộng cho implicit feedback (lượt xem, click,...).

3.4 Hybrid Model

Mô hình lai (Hybrid Model) kết hợp ưu điểm của Content-Based và Collaborative Filtering nhằm khắc phục hạn chế của từng phương pháp. Ví dụ, hệ thống có thể sử dụng thông tin mô tả món ăn để bổ sung dữ liệu cho người dùng mới (giải quyết cold-start), đồng thời tận dụng dữ liệu đánh giá để cải thiện độ chính xác của gợi ý.

3.4.1 Nguyên lý

Kết hợp các mô hình khác nhau để tận dụng ưu điểm của từng phương pháp.

3.4.2 Các dạng kết hợp phổ biến

Trọng số kết hợp (Weighted Hybrid):

Kết quả cuối cùng là trung bình có trọng số của các mô hình thành phần.

$$\hat{r}_{ui} = \alpha \hat{r}_{ui}^{CBF} + (1 - \alpha) \hat{r}_{ui}^{CF}$$

Trong đó:

- $\hat{r}_{ui}^{CBF}$: dự đoán từ Content-Based
- $\hat{r}_{ui}^{CF}$: dự đoán từ Collaborative Filtering
- $\alpha \in [0,1]$: trọng số điều chỉnh

Feature Augmentation:

Sử dụng kết quả từ mô hình này làm đầu vào cho mô hình khác.

Sử dụng đặc trưng từ Content-Based làm đầu vào bổ sung cho mô hình CF hoặc MF.

Deep Hybrid Model:

Sử dụng mạng học sâu (Deep Neural Network) để học đặc trưng từ nội dung và hành vi người dùng.

Ví dụ: Neural Collaborative Filtering (NCF) hoặc Wide & Deep Model (Google)

4. Mô hình và kết quả

Hệ thống được thiết kế gồm các khối chức năng chính:

- Tiền xử lý và trích xuất đặc trưng dữ liệu.
- Mô hình gợi ý theo từng phương pháp.
- Module đánh giá kết quả.
- Giao diện hiển thị gợi ý món ăn cho người dùng.

Phương pháp đánh giá mô hình:

Trong hệ thống gợi ý món ăn được phát triển, bài toán được đánh giá theo dạng Top-K Recommendation. Do đặc thù bài toán sử dụng dữ liệu tương tác của người dùng (implicit feedback), các thước đo được lựa chọn là Hit Rate@K và NDCG@K.

- **Hit Rate@K (HR@K):**

HR@K cho biết item mà người dùng thật sự tương tác có nằm trong danh sách gợi ý Top-K hay không. Đây là thước đo đơn giản nhưng hiệu quả cho hệ thống gợi ý.

$$HR@K = \begin{cases} 1, & \text{nếu } item_{true} \in Top - K \\ 0, & \text{ngược lại} \end{cases}$$

Sau đó HR@K trung bình của toàn bộ người dùng:

$$HR@K = \frac{1}{N} \sum_{u=1}^N HR@K_u$$

– **Normalized Discounted Cumulative Gain (NDCG@K)**

NDCG@K đánh giá dựa trên vị trí của item đúng trong danh sách gợi ý. Item đúng xuất hiện càng sớm $\rightarrow$ điểm càng cao.

$$NDCG@K = \begin{cases} \frac{1}{\log_2(i+1)}, & \text{item}_{true} \text{ ở vị trí } i \leq K \\ 0, & \text{ngược lại} \end{cases}$$

Kết quả mong đợi: mô hình lai Hybrid Model cho độ chính xác cao nhất nhờ kết hợp thông tin nội dung và hành vi người dùng.

5. Kết luận và hướng phát triển

Hệ thống gợi ý món ăn (Food Recommendation System) là một ứng dụng quan trọng trong việc cá nhân hóa trải nghiệm người dùng. Các phương pháp truyền thống như Content-Based và Collaborative Filtering có ưu điểm riêng nhưng cũng tồn tại hạn chế. Matrix Factorization và mô hình lai Hybrid giúp nâng cao hiệu quả và độ chính xác của gợi ý.

Hướng phát triển trong tương lai:

- Tích hợp phân tích cảm xúc từ đánh giá người dùng (Sentiment Analysis).
- Ứng dụng mô hình học sâu (Deep Learning) như AutoEncoder hoặc Neural Collaborative Filtering.
- Xây dựng hệ thống thực tế sử dụng Flask hoặc Streamlit kết hợp cơ sở dữ liệu PostgreSQL.

- Tối ưu mô hình theo thời gian thực bằng cách học trực tuyến (Online Learning).